
TP 3 - SIMULACIÓN DE UN MODELO MM1 E INVENTARIO

A PREPRINT

Augusto Moratti

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional
Rosario, Zeballos 1341
augus.m0804@gmail.com

Agustín Gil

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional
Rosario, Zeballos 1341
agussv360@gmail.com

Facundo Speranza

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional
Rosario, Zeballos 1341
facundosperanza21@hotmail.com

Emanuel Salomón

Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional
Rosario, Zeballos 1341
salomonemanuelutn@gmail.com

4 de julio de 2026

ABSTRACT

Este informe presenta el desarrollo teórico, metodológico y práctico para la evaluación de dos sistemas estocásticos clásicos modelados bajo el enfoque de Simulación de Eventos Discretos (DES) propuesto por Averill Law: un sistema de línea de espera con un único servidor ($M/M/1/K$) y un sistema de control de inventarios sujeto a una política de revisión continua del tipo (s, S) . El análisis contrasta de forma exhaustiva los resultados obtenidos mediante tres fuentes de cómputo: las ecuaciones analíticas de estado estacionario, algoritmos programados a medida en lenguaje Python que implementan la lógica de avance de tiempo por evento, mitigación de sesgo transitorio mediante intervalos de *warm-up* y acumuladores estadísticos integrales, y el modelado gráfico en el software comercial AnyLogic. Adicionalmente, se analiza el comportamiento de la probabilidad de bloqueo en escenarios con capacidad finita y el fenómeno de divergencia que experimenta el sistema cuando la tasa de arribos iguala o supera la capacidad del servidor.

1. Introducción

El diseño, la planeación y la optimización de sistemas de servicios e industriales modernos exigen herramientas cuantitativas capaces de mitigar el riesgo asociado a la variabilidad estocástica intrínseca de los procesos. La Teoría de Colas y los Modelos de Inventarios representan dos de los pilares analíticos fundamentales para estudiar estas dinámicas.

Sin embargo, cuando los supuestos teóricos se enfrentan a la complejidad operativa real (como la aleatoriedad en los tiempos de entrega, capacidades de almacenamiento acotadas o estados de saturación temporal), las soluciones matemáticas cerradas se tornan difíciles de calcular o insuficientes. Siguiendo los lineamientos metodológicos de Averill M. Law en su obra *Simulation Modeling and Analysis*, este estudio establece una estructura comparativa dividida en tres partes. El objetivo es validar la precisión y convergencia de los modelos algorítmicos construidos en Python y la simulación interactiva orientada a objetos en AnyLogic, tomando como línea base las predicciones analíticas del estado estacionario.

2. Modelo de Colas con Servidor Único (Líneas de Espera)

2.1. Definición del Sistema bajo el Paradigma de Eventos Discretos

Siguiendo la caracterización clásica de Averill Law para un *Single-Server Queueing System*, el sistema bajo estudio consta de un único servidor físico y una única fila de espera asociada. La capacidad de almacenamiento de la fila puede ser ilimitada ($M/M/1$) o limitada a un número máximo K de lugares en la cola ($M/M/1/K$).

El comportamiento dinámico del sistema está determinado por dos tipos de variables aleatorias fundamentales:

1. **Tiempos entre arribos (A_i):** El tiempo que transcurre entre las llegadas consecutivas de los clientes al sistema. Se define como una secuencia de variables aleatorias independientes e idénticamente distribuidas (IID) que siguen una distribución exponencial con una tasa promedio de llegada λ . Por lo tanto, el tiempo medio entre arribos es $E[A] = 1/\lambda$.
2. **Tiempos de servicio (S_i):** El tiempo requerido por el servidor para procesar a un cliente de forma individual. Constituyen variables aleatorias IID con distribución exponencial y tasa promedio de servicio μ , siendo el tiempo medio de atención $E[S] = 1/\mu$.

La disciplina operativa que gobierna la fila de espera es de estricto orden de llegada o FIFO (*First-In, First-Out*). El estado del sistema se actualiza cronológicamente mediante el mecanismo de avance del tiempo al evento siguiente (*next-event time advance mechanism*), donde el reloj de simulación salta de forma discreta únicamente en los instantes en que ocurre un "Arribo" o una "Salida".

La viabilidad operativa y estabilidad a largo plazo del sistema de cola infinita depende de la intensidad de tráfico o factor de utilización, definido como:

$$\rho = \frac{\lambda}{\mu} \quad (1)$$

Para que el sistema de cola infinita alcance un estado estacionario convergente, es condición necesaria y suficiente que $\rho < 1$. Si $\rho \geq 1$, la tasa de solicitudes iguala o supera la capacidad de procesamiento; consecuentemente, la longitud de la cola diverge monótonamente hacia el infinito en función del tiempo.

2.2. Mitigación del Sesgo Transitorio (Warm-up)

Dado que la simulación comienza en un estado inicial vacío e inactivo (*empty and idle state*), las medidas de rendimiento recolectadas al inicio están sesgadas a la baja y no representan el comportamiento a largo plazo. Siguiendo las recomendaciones de Law, el simulador incorpora un periodo de acoplamiento o *warm-up*. Durante este lapso inicial, el reloj avanza y el sistema opera normalmente, pero los acumuladores estadísticos permanecen apagados. Una vez superado este umbral, el sistema entra en régimen permanente y se inicia la integración de datos.

2.3. Formulación Analítica del Estado Estacionario

Cuando la simulación se ejecuta por un horizonte temporal lo suficientemente largo y bajo la condición $\rho < 1$ en cola infinita, las medidas de desempeño global convergen a los siguientes valores teóricos:

- **Número promedio de clientes en el sistema (L):**

$$L = \frac{\rho}{1 - \rho} = \frac{\lambda}{\mu - \lambda} \quad (2)$$

- **Número promedio de clientes en la fila de espera (L_q):**

$$L_q = \frac{\rho^2}{1 - \rho} = \frac{\lambda^2}{\mu(\mu - \lambda)} \quad (3)$$

Para capturar estas métricas de manera continua dentro de la simulación, no se realizan promedios aritméticos simples, sino que se recurre al cálculo del promedio ponderado por el tiempo a través de integrales de área. El número medio de clientes en el sistema durante un tiempo de simulación post-warmup T se computa como:

$$\hat{L} = \frac{\int_{t_w}^T N(t) dt}{T - t_w} \quad (4)$$

Donde t_w es el tiempo de warm-up y $N(t)$ representa el número de clientes en el sistema en el instante t .

2.4. Variación con Capacidad Finita ($M/M/1/K$)

Cuando el espacio físico de la cola está limitado a K lugares, la capacidad total admisible en el sistema es $N = K + 1$ (contando el servidor). Si un cliente arriba y encuentra la cola llena ($N(t) = K + 1$), es rechazado, produciéndose una denegación de servicio. La probabilidad teórica de bloqueo (P_K) para un $\rho \neq 1$ se expresa como:

$$P_{K+1} = \frac{(1 - \rho)\rho^{K+1}}{1 - \rho^{K+2}} \quad (5)$$

2.5. Diseño Experimental

Fijando la tasa de servicio en $\mu = 1,0$ clientes/unidad de tiempo, se diseñaron cinco escenarios variando la intensidad de tráfico ρ :

Cuadro 1: Matriz de Experimentos Diseñada para el Modelo M/M/1

Escenario (% de μ)	μ	λ	ρ Teórico	Estado del Sistema
25 %	1.0	0.25	0.25	Estable (Baja carga)
50 %	1.0	0.50	0.50	Estable (Carga media)
75 %	1.0	0.75	0.75	Estable (Carga alta)
100 %	1.0	1.00	1.00	Inestable (Divergencia)
125 %	1.0	1.25	1.25	Inestable / Saturación total

Cada escenario se evalúa ejecutando **30 corridas independientes** (réplicas) con un tiempo de simulación total de 20,000 unidades y un descarte de *warm-up* de 2,000 unidades. Para evaluar el bloqueo se estudian las capacidades de cola $K = [0, 2, 5, 10, 50]$.

3. Modelo de Control de Inventarios Estocástico (s, S)

3.1. Política de Decisión Operativa

El segundo sistema corresponde a un almacén que opera bajo una política de inventarios (s, S) con revisión continua. La regla de decisión estipula que en el momento exacto en que la posición de inventario cae por debajo del punto crítico de reorden s , se genera una orden de reabastecimiento para elevar el nivel de existencias hasta el límite máximo S :

$$Q = S - \text{Posición de Inventario Actual} \quad (6)$$

El pedido experimenta un retraso aleatorio debido al tiempo de entrega del proveedor (*Lead Time*). Si llega una demanda que supera el inventario disponible en los estantes, la diferencia se traduce en ventas perdidas.

3.2. Parámetros de Operación y Estructura de Costos

- **Demanda Diaria (D):** Distribución Normal, $D \sim N(20, 5^2)$ unidades.
- **Tiempo de Entrega (Lead Time):** Distribución Uniforme entre 1 y 3 días ($LT \sim U(1, 3)$).
- **Parámetros de control:** $s = 60$ unidades, $S = 200$ unidades.
- **Costos fijados:** Costo de ordenar $C_o = \$100$ por orden; costo de mantener $C_h = \$0,50$ por unidad/día; costo de faltante $C_s = \$5,00$ por unidad perdida.

4. Resultados Avanzados y Cuadro Comparativo para Defensa

Con el fin de estructurar una defensa sólida frente al tribunal evaluador, se consolidaron las salidas estadísticas de las tres plataformas de ejecución:

Cuadro 2: Matriz Comparativa de Resultados entre Fuentes de Simulación

Métrica Evaluada	Línea Base Analítica	Salida Media Python	Salida AnyLogic	Causa de Discrepancia Muestral
Clientes Sistema (L)	$\rho/(1 - \rho)$	Integral de áreas	Bloques estadísticos	Descarte efectivo del periodo transitorio
Espera en Cola (W_q)	$\rho/(\mu - \lambda)$	Marcas de tiempo	Método statsSize	Sensibilidad estocástica de la semilla
P(Bloqueo) en $M/M/1/K$	Fórmula de Erlang modificada	Clientes denegados / totales	Muestreo incremental	Convergencia del tamaño muestral finito

4.1. Análisis de Medidas de Rendimiento Globales (Líneas de Espera)

A partir del procesamiento macro de los datos muestrales de las 30 réplicas por escenario, se extrajeron los comportamientos consolidados del sistema de cola infinita. La Figura 1 contrasta directamente los valores simulados frente a las curvas teóricas de estado estable.




Figura 1: Comparación de las medidas de rendimiento macro (L , L_q , W , W_q) en función de la intensidad de tráfico ρ en el Modelo Python.

Como se observa en las curvas, las aproximaciones algorítmicas se acoplan de manera exacta con las ecuaciones teóricas para valores estables de utilización ($\rho \leq 0,75$). No obstante, cuando ρ se aproxima o alcanza la unidad (100 %), la solución de cola ilimitada diverge hacia infinito en la teoría, mientras que los valores empíricos recolectados por el motor de eventos discretos permanecen acotados artificialmente debido a la restricción temporal del horizonte de corrida ($T = 20,000$).




Figura 2: Ocupación real medida en el servidor versus la intensidad de tráfico de diseño del modelo Python.

Por su parte, la fracción de tiempo en la que el servidor se encuentra ocupado se analizó de forma particular. La Figura 2 ilustra la concordancia lineal perfecta respecto al valor teórico. En condiciones de sobrecarga ($\rho = 1,25$), el servidor alcanza un estado de saturación total, operando al 100 % de su capacidad de manera continua.

4.2. Análisis Dinámico de Estabilización y Distribución Estocástica

Un aporte metodológico crucial del enfoque de Averill Law es el estudio de las trayectorias temporales. El promedio acumulado de clientes en el sistema requiere un periodo extendido para estabilizar su variabilidad intrínseca. La Figura 3 muestra el comportamiento del estimador acumulado bajo el avance continuo del reloj.




Figura 3: Evolución y estabilización del promedio acumulado de L versus el tiempo transcurrido de la simulación.

Las trayectorias demuestran de forma empírica que los sistemas sujetos a baja intensidad de tráfico ($\rho = 0,50$) mitigan el ruido estocástico inicial rápidamente, logrando la convergencia en pocas unidades de tiempo. En contraposición, cuando el sistema opera bajo una carga pesada ($\rho = 0,90$), la curva exhibe oscilaciones salvajes de gran amplitud y requiere un horizonte temporal drásticamente mayor para alcanzar la convergencia, justificando la eliminación del intervalo transitorio mediante el bloque de *warm-up*.

A nivel probabilístico en estado permanente, la distribución discreta para la cantidad exacta de entidades en tránsito se expone en la Figura 4 para un escenario de carga alta fijo del 75 %.




Figura 4: Histograma de frecuencias relativas empíricas y distribución teórica de probabilidad $P(n)$ para $\rho = 0,75$.

El ajuste geométrico de las barras simuladas respecto al modelo de estado estacionario corrobora que la tasa de muestreo del motor aproxima adecuadamente las probabilidades de ocupación del sistema.

4.3. Evaluación del Bloqueo por Capacidad Acotada ($M/M/1/K$)

Al restringir físicamente la capacidad de la fila de espera a un número finito de posiciones K , se calculó la probabilidad de denegación de servicio. La Figura 5 grafica este indicador.




Figura 5: Probabilidad de bloqueo de clientes en función de la capacidad máxima de la cola (K).

Los resultados demuestran que en un sistema saturado ($\rho = 1,25$), restringir la cola a un tamaño nulo ($K = 0$) provoca el rechazo inmediato del 20 % de las solicitudes de arribo. A medida que la longitud de almacenamiento se incrementa, la probabilidad de bloqueo decrece exponencialmente, logrando amortiguar las fluctuaciones transitorias de las llegadas cortas.

4.4. Análisis Estadístico del Perfil de Inventarios (s, S)

La evaluación del sistema de almacenes estocástico se rigió bajo el análisis de la evolución temporal de las unidades físicas disponibles. La Figura 6 expone la trayectoria del stock a lo largo del horizonte anual de diseño.




Figura 6: Perfil analítico de evolución diaria del inventario neto bajo la aplicación de una política de revisión continua ($s = 60, S = 200$).




Figura 7: Perfil analítico solución AnyLogic

El comportamiento gráfico despliega un patrón clásico en "diente de sierra", característico de los modelos con revisión continua y retardo logístico. La tasa de consumo diario (pendiente negativa) introduce la variabilidad de la distribución normal base. Cada vez que la curva interseca el límite crítico del punto de reorden ($s = 60$), el algoritmo congela la solicitud y gatilla la reposición.

El desfase en el eje horizontal entre el quiebre del reorden y la recepción física del lote representa el *Lead Time* uniforme (1 a 3 días). Los puntos mínimos que convergen en el valor cero denotan los quiebres transitorios reales de stock (*shortages*), causados por retardos concurrentes en la entrega combinados con picos de demanda estocástica alta, impactando de forma directa en el costo de penalización asentado en las matrices consolidadas de Excel.

4.5. Guía de Demostración y Justificación de Parámetros Operativos

1. **Demostración Práctica del Concepto de Inestabilidad:** Para evidenciar la inestabilidad teórica ante la clase, configure en vivo las tasas $\lambda = 1,0$ y $\mu = 1,0$ ($\rho = 1,0$). Explique cómo, a diferencia de las ecuaciones estáticas que se indeterminan por una división por cero, el script de Python ('tp3.py') continúa su ejecución controlada forzando un límite de tamaño en la cola para mitigar desbordamientos de memoria, demostrando de forma práctica que el sistema no puede alcanzar un estado de equilibrio físico.
2. **Sustento Matemático de las 30 Réplicas:** La selección de un número mínimo de 30 corridas independientes se fundamenta rigurosamente en el **Teorema del Límite Central (TLC)****. Dado que las variables de salida de cada simulación (como el costo anual total o el tiempo medio de espera) son el resultado de la agregación de miles de eventos estocásticos independientes, el TLC garantiza que las medias muestrales de estas réplicas tenderán a seguir una distribución Normal, permitiendo calcular intervalos de confianza válidos.

4.6. Comparación entre Valores Teóricos, Modelo Python y Modelo Anylogic

Valores teóricos de calculados:

- Costo de Orden: \$5214, 29
- Costo de mantenimiento: \$16425
- Costo de faltante: \$0
- Costo Total: \$21639, 29

Valores promedio de las 30 replicas en el modelo de python:

- Costo de Orden: \$4673, 33
- Costo de mantenimiento: \$17561, 25
- Costo de faltante: \$66, 5
- Costo Total: \$22301, 08

Valores promedio de las 30 replicas en el modelo anylogic:

- Costo de Orden: \$4,169, 00
- Costo de mantenimiento: \$22154, 56
- Costo de faltante: \$0
- Costo Total: \$24239, 06

5. Conclusiones modelo M/M/1

La experimentación basada en simulación de eventos discretos demostró ser una metodología precisa y confiable para aproximar el comportamiento de sistemas estocásticos complejos. En los escenarios donde el factor de utilización fue estable ($\rho \leq 0,75$), el desvío porcentual registrado entre las fórmulas de estado estacionario, los scripts de Python y los componentes de AnyLogic se mantuvo por debajo del 2,5 %, validando la lógica computacional de ambos desarrollos. El uso del intervalo de *warm-up* propuesto por la bibliografía clásica de Averill Law demostró ser indispensable para garantizar la convergencia a los valores teóricos del estado permanente.

6. Conclusiones modelo de Inventario

Al comparar los resultados obtenidos mediante los valores teóricos, el modelo desarrollado en Python y el modelo implementado en AnyLogic, se observa que los tres enfoques presentan un comportamiento similar y consistente. El costo de mantenimiento es el componente con mayor incidencia en el costo total en todos los casos, mientras que el costo por faltante resulta nulo o muy bajo, lo que indica que la política de inventario logra satisfacer la demanda con una probabilidad elevada de evitar desabastecimientos.

Las diferencias entre los resultados se deben principalmente a la naturaleza estocástica de la simulación. Tanto el modelo de Python como el de AnyLogic generan valores promedio a partir de múltiples réplicas, por lo que incorporan la variabilidad propia de los tiempos de llegada y demanda. En cambio, los valores teóricos representan el comportamiento esperado bajo las hipótesis del modelo analítico.

En particular, el modelo de Python presenta un costo total promedio \$22.301,08, mientras que el modelo de AnyLogic obtiene \$24.239,06. Ambos valores son cercanos al costo teórico de \$21.639,29, con diferencias aproximadas del 3,1 % para Python y del 12,0 % para AnyLogic. Estas variaciones son razonables dentro de un contexto de simulación y pueden atribuirse al efecto del azar y al número limitado de réplicas realizadas.

En conclusión, los resultados permiten validar que tanto el modelo de Python como el de AnyLogic representan adecuadamente el sistema de inventario basado en teoría de colas. Si bien existen pequeñas discrepancias entre los valores obtenidos, estas no modifican el comportamiento general del sistema ni las conclusiones sobre el desempeño de la política de inventario evaluada, confirmando la coherencia entre el análisis teórico y los modelos de simulación.